

1 Gaussowski Naiwny Klasyfikator Bayesa (Gaussian Naive Bayes)

To jeden z prostych, ale skutecznych algorytmów w dziedzinie uczenia maszynowego, który służy do klasyfikacji. Jego działanie opiera się na twierdzeniu Bayesa i pozwala na oszacowanie prawdopodobieństwa, że dany obiekt należy do konkretnej klasy.

Istotne cechy tego klasyfikatora:

1. Zastosowanie do danych ciągłych: W odróżnieniu od tradycyjnego Naiwnego Bayesa, który działa na danych dyskretnych, Gaussowski Naiwny Bayes jest wykorzystywany w sytuacjach, gdy cechy (predyktory) mają charakter ciągły.
2. Założenie o rozkładzie normalnym: Algorytm przyjmuje, że wartości numeryczne każdej cechy w obrębie danej klasy rozkładają się według rozkładu normalnego, co sugeruje, że dane koncentrują się wokół średniej.
3. "Naiwne" założenie: Klasyfikator operuje na zasadzie, że cechy są niezależne od siebie, co w rzeczywistości zdarza się rzadko (stąd określenie "naiwny"). Pomimo tego uproszczenia, algorytm sprawdza się doskonale w wielu rzeczywistych zastosowaniach.

Etapy działania klasyfikatora:

1. Działania wykonywane na zbiorze treningowym

- (a) Obliczenie prawdopodobieństwa dla każdej z klas

$$P(C) = \frac{\text{liczba obiektów klasy w systemie treningowym}}{\text{liczba obiektów w systemie treningowym}}$$

- (b) Obliczenie statystyki dla każdego z atrybutów (działanie to jest wykonywane dla każdej klasy oddzielnie)

μ – *rednia*

σ^2 – *wariancja*

$$C : (\mu_1, \sigma_1^2), (\mu_2, \sigma_2^2), \dots, (\mu_n, \sigma_n^2)$$

2. Operacje wykonywane na każdym obiekcie zbioru testowego

Dla każdej klasy wykonaj działania:

- (a) Obliczenie logarytmu naturalnego z $P(C)$

$$\ln(P(C))$$

(b) Dla każdego z atrybutów danego obiektu policz

$$P(a_i|C) = \frac{1}{\sqrt{2\pi\sigma_i^2}} * e^{-\frac{(a_i - \mu_i)^2}{2\sigma_i^2}}$$
$$\ln(P(a_i|C))$$

(c) Sumowanie wyniku końcowego dla pojedynczej klasy

$$\ln(P(C)) + \sum \ln(P(a_i|C))$$

Do listy predykowanych klas trafia klasa z największym wynikiem dla danego obiektu testowego.

3. Końcowe wyliczenie dokładności to wykonanie działania

$$accuracy = \frac{\text{poprawne predykcje}}{\text{liczba próbek zbioru testowego}}$$