

1 Regresja Logistyczna - teoria

Regresja logistyczna to metoda uczenia maszynowego służąca do klasyfikacji, czyli przewidywania przynależności obiektu do jednej z klas na podstawie jego cech.

Najczęściej stosuje się ją do problemów binarnych, gdzie:

- 0 oznacza jedną klasę,
- 1 oznacza drugą klasę.

Model oblicza liniową kombinację cech wejściowych:

$$z = w * x + b$$

a następnie przekształca wynik za pomocą funkcji sigmoidalnej:

$$\sigma(z) = \frac{1}{1 + e^{-x}}$$

Wynik funkcji sigmoidalnej jest interpretowany jako prawdopodobieństwo przynależności do klasy. Podczas treningu model uczy się wartości wag w oraz biasu b poprzez minimalizację funkcji kosztu metodą optymalizacji, najczęściej gradient descent.

Regresja logistyczna jest szeroko stosowana m.in. w:

- ocenie ryzyka kredytowego,
- diagnostyce medycznej,
- wykrywaniu spamu,
- klasyfikacji klientów i użytkowników.

2 Implementacja

Działania wykonywane na zbiorze treningowym

1. Policzenie średniej oraz odchylenia standardowego dla każdego z atrybutów systemu treningowego do przeskalowania danych (wartości średniej i odchylenia pomogą także przeskalować system testowy). Skalowanie danych odbywa się za pomocą wzoru:

$$x' = \frac{x - \mu}{\sigma}$$

gdzie: x - przeskalowywana wartość

μ - średnia

σ - odchylenie standardowe

2. Utworzenie wektora wag, w związku z tym że nasz system posiada 14 atrybutów wektor wag będzie posiadał 14 wag, początkowo wszystkie wagi będą równe 0.
3. Utworzenie biasu (b) i ustawienie początkowe na wartość 0, parametru learning rate (α) z wartością 0.01, oraz ustawienie liczby iteracji na 100
4. Pętla uczenia

- (a) dla jednej próbki $x_i = [x_1, x_2, \dots, x_{14}]$ obliczamy wartość ze wzoru

$$z_i = w_1x_1 + w_2x_2 + \dots + w_{14}x_{14} + b$$

- (b) Zamiana wyniku na prawdopodobieństwo:

$$\sigma(z) = \frac{1}{1 + e^{-x}}$$

Wynik ten uznawany jest za prawdopodobieństwo y'

- (c) Obliczenie błędu

$$error = y' - y$$

- (d) Liczenie gradientu dla każdej z wag

$$gradient_j + = error * x_i$$

- (e) Liczenie gradientu dla biasu

$$gradient_b + = error$$

Kroki od a do e są wykonywane dla każdego obiektu z systemu treningowego. Po przejściu przez wszystkie obiekty z systemu treningowego wykonujemy dalsze kroki.

- (f) Uśrednienie gradientu dla wag

$$gradjent_j = \frac{gradient_j}{n}$$

n - liczba obiektów w systemie treningowym

- (g) Aktualizacja wag

$$w_j = w_j - \alpha * gradient_j$$

- (h) Aktualizacja biasu

$$b = b - \alpha * gradient_b$$

Po przejściu całego uczenia czyli wykonaniu się głównej pętli 100 razy mamy wyuczone wagi oraz bias.

Działania wykonywane na systemie testowym.

1. Przeskalowanie danych z systemu testowego za pomocą średniej i odchylenia standardowego policzonych dla systemu treningowego, wzór na przeskalowanie danych jest taki sam.
2. Dla każdej próbki testowej:
 - (a) Liczymy z_i ze wzoru

$$z_i = w_1x_1 + w_2x_2 + \dots + w_{14}x_{14} + b$$

używając wyuczonych wag oraz biasu.

- (b) Zamiana wyniku na prawdopodobieństwo:

$$\sigma(z) = \frac{1}{1 + e^{-x}}$$

Wynik ten uznawany jest za prawdopodobieństwo y'

- (c) Zamiana na klasę: jeśli $y' \geq 0.5$ to predykowana klasa przyjmuje wartość 1, w przeciwnym razie 0

Po wyliczeniu wszystkich predykcji klas liczymy accuracy ze wzoru:

$$accuracy = \frac{\text{liczba poprawnych predykcji}}{\text{liczba wszystkich obiektów}}$$